RELATÓRIO DE PESQUISA

QUEM FAZ O QUÊ E A QUE CUSTO?

Claude · Gemini / Antigravity · Codex

Cotas, rankings, telemetria e uma rotina para gastar contexto com intenção.

LAY® / CADERNO DE PESQUISA · 31 OUT 2026

DADOS DE BENCHMARK NÃO SÃO COTAS. RELATOS NÃO SÃO RANKINGS. Este relatório separa as evidências e mostra onde elas ajudam numa decisão diária.

Sumário Executivo: A Decisão Baseada em Dados

2.060	33	313K
CHAMADAS	SUBAGENTES	CACHE LIDO / CHAMADA

Decisão executiva. Para o fluxo de desenvolvimento sem IDE analisado neste estudo, não há respaldo técnico ou empírico para declarar Claude, Codex ou Antigravity um vencedor universal. A hipótese operacional a testar adota superfícies separadas com papéis calibrados:

1. Codex Desktop opera como painel humano de filas, worktrees paralelas e revisão de diffs;
2. Claude Code / Desktop assume o planejamento arquitetural, especificações formais e revisão crítica de alto risco em baixo volume de requisições;
3. Antigravity / Gemini executa tarefas que demandam contexto multimodal, navegação web, crawl e verificação visual no browser quando necessárias;
4. Scripts determinísticos locais assumem operações mecânicas previsíveis (hash, recorte, conversão, validação geométrica e empacotamento), reduzindo o uso de LLM em trabalho que não exige julgamento generativo.

Essa separação reconhece que MCP conecta ferramentas, mas não transfere cotas nem unifica assinaturas. A telemetria local oferece uma explicação compatível com o esgotamento rápido da cota do Claude no caso estudado: 2.060 chamadas, 33 subagentes e média de 313 mil tokens de cache lidos por chamada, com crescimento de 155 milhões de tokens de cache em cerca de cinco horas. Ela não revela a fórmula da cota do fornecedor.

Escopo e método. Pesquisa consolidada em 31 de outubro de 2026. Separa documentação oficial, benchmarks com metodologia, experimentos independentes com artefatos e relatos comunitários (qualitativos, sem validade estatística). Preços/cotas vêm dos fabricantes; desempenho vem do benchmark primário. A telemetria é um estudo de caso local, não uma amostra de mercado; o rascunho histórico do Argon permanece como hipótese, não como fonte factual.

1 O LIMITE CAIU PORQUE O CONTEXTO SE MULTIPLICOU

JANELA LOCAL · 07:55 → 12:57

+24 SUBAGENTES	**+986** CHAMADAS	**+155,1M** TOKENS DE CACHE LIDOS

O esgotamento de cotas em agentes autônomos pode acompanhar a multiplicação do contexto em pipelines paralelos. No retrato de telemetria local de 31/10/2026, o Claude Code registrou:

- 1 sessão principal e 33 subagentes;
- 2.060 chamadas ao modelo;
- 645.363.759 tokens de cache lidos e 11.060.887 tokens de cache escritos;
- 2.803.653 tokens de saída e 851.360 tokens de raciocínio.

Esses valores representam uma média descritiva de 313.283 tokens de cache lidos por chamada. Entre 07:55 e 12:57, o ambiente instanciou 24 novos subagentes e realizou 986 chamadas adicionais; o cache lido expandiu em 155.138.357 tokens sem nenhum evento de compactação registrado nesse intervalo. O modelo identificado como `claude-opus-5-5` respondeu por 61,8% das chamadas e 83,0% de todo o cache lido. Esses dados revelam uma operação que reapresentou um contexto maciço centenas de vezes em paralelo.

A documentação oficial da Anthropic detalha o mecanismo: cada turno de agente incorpora histórico, arquivos lidos, instruções do projeto (`CLAUDE.md`), saídas de ferramentas e o prompt do usuário. Os limites são compartilhados entre Claude na web, Claude Desktop e Claude Code. A orientação oficial recomenda:

- Abrir contextos novos para tarefas não relacionadas;
- Executar `/compact` periodicamente durante sessões longas;
- Usar `/clear` rigorosamente ao concluir cada tarefa;
- Monitorar o volume por meio de `/context`;
- Referenciar arquivos por caminhos em vez de colar conteúdos integrais no prompt;

■ Manter regras de projeto concisas e modulares (Anthropic, uso e limites do Claude Code; Anthropic, limites de uso).

A telemetria do Antigravity confirmou que a migração de fornecedor não elimina o gargalo: registrou 253 conversas, 7.065 chamadas e 443.261.118 tokens de cache lidos. O log documentou o evento real “Individual quota reached” com suspensão temporária do lote e gravação de flag de pausa. Nenhum plano de consumidor é infinito.

Sinal Observado na Telemetria	Diagnóstico Seguro	Ação Operacional Recomendada
Média de 313 mil tokens de cache lidos por chamada	Contexto acumulado e reenviado continuamente	Encerrar a unidade em handover e iniciar sessão nova com `/clear`
24 subagentes criados em 5 horas	Paralelismo sem isolamento multiplicou o contexto ativo	Limitar concorrência a 1 orquestrador e até 2 workers de alta capacidade
986 chamadas sem nova compactação	Execução em loop contínuo sem redução de estado	Compactar dentro da tarefa; nunca tratar compactação como sessão infinita
Evento de cota atingida no Antigravity	Limite dinâmico presente em todos os fornecedores	Interromper despacho via flag de pausa; processar etapas mecânicas em script local

Hipótese comunitária sob monitoramento: Relatos de usuários indicam que reabrir sessões após conclusão de subagentes pode provocar regravação volumosa de cache (243 mil a 399 mil tokens em casos reportados). Trata-se de hipótese qualitativa que deve ser aferida no ambiente de teste antes de ser classificada como bug oficial (relato de cache no Claude Code).

2 RANKINGS COMPARAM TAREFAS E NÃO APLICATIVOS

TRÊS TESTES · TRÊS PERGUNTAS DIFERENTES

Cada gráfico mantém a escala e o cenário da própria bateria. Use o resultado para escolher o que testar; não para ordenar todos os modelos de forma geral.

Código em tarefas agênticas

Artificial Analysis Intelligence Index v5.0 · FrontierCode 2.0 · 31 out. 2026



46% contra 42% neste benchmark. A diferença não prevê sucesso em qualquer repositório.

Terminal e execução de ferramentas

Artificial Analysis · Terminal-Bench-Science · snapshot de 31 out. 2026



Use como sinal para tarefas de terminal semelhantes; não compare com SWE-bench nem com uso geral.

Custo por tarefa na mesma bateria

Artificial Analysis Intelligence Index v5.0 · USD por tarefa · mesma mistura de tarefas



O benchmark favorece Sol em custo observado; confirme qualidade e retrabalho no piloto do seu projeto.

Leitura prática: experimente Opus para mudanças de código difíceis, Astra em tarefas de terminal e Sol em trabalho repetitivo sensível a custo. São candidatos para piloto. Não foi encontrado resultado comparável de Gemini/Antigravity nesses mesmos

cenários; seu uso visual decorre das ferramentas do produto, sem score equivalente nesta pesquisa.

Fonte: Artificial Analysis Intelligence Index v5.0 · snapshot de 31 out. 2026. Custo por tarefa pertence à bateria publicada, não à assinatura do leitor.

Comparações técnicas exigem alinhamento de escopo, dataset e infraestrutura:

- SWE-bench afere resolução de issues reais sob um scaffold de agente padronizado (o subconjunto Verified possui 500 instâncias auditadas por humanos, enquanto o harness Bash Only isola o agente);
- Terminal-Bench 4.0 avalia execução estrita em terminal (66 tarefas, até 500 passos, média de 3 repetições sob infraestrutura controlada);
- Artificial Analysis unifica avaliações de código, ciência e raciocínio com métricas de custo e latência;
- LLM Stats calcula ratings relativos com estimativa de incerteza estatística;
- OpenRouter Rankings expõe volume público de tráfego de seu marketplace, indicando adoção na plataforma, mas não qualidade técnica (metodologia Artificial Analysis; metodologia LLM Stats; OpenRouter Rankings).

Evidências da Bateria Artificial Analysis (Snapshot de 31/10/2026)

Na metodologia v5.0 da Artificial Analysis, observou-se:

1. FrontierCode 2.0 (tarefas agênticas complexas de código):

- Claude Opus 5.5 (esforço max): 46%

- GPT-6 Astra (esforço max): 42%

- GPT-6.1 Sol Terra: 42%

- Claude Sonnet 5.5: 42%

(Diferença estreita de 4 pontos percentuais; orienta hipótese de piloto, sem comprovar superioridade universal).

2. Terminal-Bench-Science (execução autônoma de ferramentas em terminal):

- GPT-6 Astra (esforço max): 63%

- Claude Opus 5.5 (esforço max): 59%

3. Custo por Tarefa Observado na Mesma Bateria:

- Claude Opus 5.5 max: US$ 10,04

- GPT-6 Astra max: US$ 6,24

- GPT-6 Sol max: US$ 1,27

No leaderboard ao vivo capturado em 31/10/2026, Gemini 4 Carbon High marcou índice 59, Opus 5.5 max 58 e Astra max 57. Dias antes, a publicação inicial mostrava ordem distinta. A alternância comprova que esforço de raciocínio, versão e data alteram rankings dinâmicos.

Para geração e edição de imagens, o leaderboard de preferência humana cega da Artificial Analysis registrou GPT Image 2.5 Sunburst max em primeiro lugar na geração (Elo 1222±10, 13.014 amostras) e na edição (Elo 1199±11, 18.250 amostras), com Nano Banana 2.1 em 4º na geração (Elo 1176±12) e na faixa de 4º a 7º na edição (Elo 1151±13) (geração; edição).

Pergunta Técnica	Evidência Apropriada	Conclusão Permitida	Conclusão Proibida
Qual modelo resolve issues sob scaffold fixo?	SWE-bench com mesmo agente e versão	Comparar modelos dentro daquele protocolo exato	Afirmar que "o modelo resolve 90% de qualquer software"
Qual configuração teve maior taxa no terminal?	Terminal-Bench com repetições e esforço documentados	Selecionar candidato prioritário para teste local	Comparar pontuação de terminal com SWE-bench
Qual modelo lidera preferência visual cega?	Leaderboard cego de imagem datado	Escolher ponto de partida para geração de assets	Presumir precisão de alpha ou conformidade de UI
O que indica o tráfego do OpenRouter?	Dados de requisições e tokens do marketplace	Entender demanda relativa daquela plataforma	Declarar mix ideal universal ou qualidade de modelo
Qual o valor de testes do Reddit?	Post com logs, código e ambiente reproduzíveis	Mapear hipóteses e modos de falha reais	Tratar relatos isolados como consenso estatístico

3 ASSINATURAS, APLICATIVOS E CLIS NÃO SE FUNDEM

Os três provedores disponibilizam clientes oficiais para operação sem IDE, mantendo contas, cobrança e cotas estritamente isoladas:

- Claude Code: integrado à assinatura Pro/Max no terminal e na aba Code do Claude Desktop;
- Codex: disponível como aplicativo de desktop (Windows, macOS, Linux), CLI e web para planos ChatGPT;
- Antigravity 2.0: aplicativo autônomo e CLI `agy` com suporte nativo a subagentes, Skills, MCP e automação de navegador (Claude Code no plano; Codex e plano ChatGPT; Antigravity 2.0).

A Regra de Isolamento de Cotas e MCP

O protocolo MCP (Model Context Protocol) interliga ferramentas e servidores de contexto; ele não transfere privilégios nem cotas de um provedor para outro. Se o Claude Code for executado com `ANTHROPIC_API_KEY` preenchida no ambiente, as requisições serão faturadas por token na API comercial, desconsiderando a assinatura Pro. O mesmo se aplica ao excedente do Antigravity quando configurado para "Always" e a ferramentas externas (Claude Code CLI; OpenAI, Sign in with ChatGPT; Google One, Antigravity).

Superfície Operacional	Papel Recomendado	Capacidade Verificada	Limite Inegociável
Codex Desktop	Painel humano de filas, worktrees, branches e aprovação de diffs	Gerenciamento de múltiplos agentes e worktrees paralelas	Não herda cotas de terceiros; exige revisão humana pré-merge
Claude Desktop / Code	Arquitetura, contratos, revisão crítica e raciocínio profundo	Suporte a subagentes, MCP e worktrees documentados	Cota dinâmica Pro de 5h compartilhada entre web, app e CLI
Antigravity / `agy`	Contexto multimodal alargado, navegação web e QA visual	Orquestração com browser, Skills, MCP e keyring nativo	Cotas temporais e semanais; bloqueio dinâmico por fornecedor
Scripts Locais & GPU	Hash, resize, conversão, validação de arquivos e testes	Execução determinística, custo zero de token, reprodutibilidade	Não realizam julgamento semântico ou direção de arte

4 ARQUITETURA DE ENCAMINHAMENTO E ROTINA DIÁRIA

UM PEDIDO → UM DONO → UM GATE HUMANO

01 / ROTINA	02 / BUILD	03 / RISCO	04 / VISUAL
SCRIPTS	**CODEX**	**CLAUDE**	**GEMINI**
hash · conversão resize · fixtures	tarefas delimitadas worktree · testes	arquitetura revisão crítica	crawl · multimodal QA em browser

HUMANO: CONTRATO · TESTES · DIFF · APROVAÇÃO

Papéis propostos para piloto; autenticações e cotas seguem separadas.

A orquestração proposta substitui a busca por um "modelo vencedor" por encaminhamento de tarefa: primeiro scripts para trabalho determinístico; Codex para implementação delimitada após piloto; Claude para decisões arquiteturais e revisão crítica; Gemini/Antigravity para pesquisa, multimodalidade e QA visual quando essas capacidades forem necessárias. O dono humano fecha cada tarefa com contrato, evidência e aprovação. Os papéis são uma hipótese calibrável, sem cota compartilhada entre fornecedores.

Rotina Diária para Conter Contexto e Cota

1. Comece pela tarefa, não pelo modelo: escreva objetivo, arquivos permitidos, commit de origem, entrada, saída e teste de aceite. Consulte o medidor de cada fornecedor separadamente.

2. Tire o trabalho mecânico do caminho: rode primeiro scripts locais para hash, resize, conversão, fixtures e outras operações determinísticas.
3. Use Claude em pontos de decisão: peça um plano focado para arquitetura ou risco; implemente em uma unidade delimitada e feche a sessão com resumo. Em tarefas distintas, use contexto novo e `/clear`; em tarefa longa, consulte `/context` e compacte com `/compact`.
4. Encaminhe a execução uma vez: Codex para implementação modular após piloto; Gemini/Antigravity para pesquisa/crawl ou QA visual que use browser. Evite mandar o mesmo prompt para os três sem uma pergunta de comparação definida.
5. Feche com evidência: execute testes, revise o diff e salve um handoff curto com arquivos, resultados, medidores antes/depois e próxima ação. Ao atingir aviso de quota, pare novos despachos daquele serviço.

Esse ciclo busca reduzir releituras de contexto e chamadas redundantes. Não há dado neste estudo que permita prometer uma porcentagem de economia ou prever a cota restante.

Matriz de Classes de Trabalho e Políticas de Risco

Classe de Trabalho	Dono da Decisão	Executor Inicial	Verificação Obrigatória	Política de Custo e Risco
Arquitetura, shaders core, contratos e licenças	Agente de alta capacidade + Humano	Claude Opus ou GPT Astra (após piloto)	Revisão independente, testes e typecheck estrito	1 agente por decisão; sem paralelismo no mesmo contrato
Implementação React/R3F/GSAP e módulos	Orquestrador fixa contrato e interfaces	Worker em worktree isolado (Codex)	Suíte de testes unitários e teste de integração	Paralelizar somente módulos com arquivos disjuntos
Vitest, mocks, fixtures e scripts repetitivos	Especificação aprovada pelo orquestrador	Codex ou worker rápido após piloto	Suíte executada com cobertura útil comprovada	Lote delimitado; medir retrabalho antes de escalar
Playwright, inspeção DOM, WebGL e QA por pixel	Orquestrador avalia evidência capturada	Antigravity / runner de browser	Screenshots, console limpo e diff visual	Agente visual executa; aprovação final permanece humana
Geração de assets visuais ou sonoros	Direção de arte e referência recortada	GPT Image Sunburst ou Nano Banana 2.1	Alpha, silhueta e prancha comparativa lado a lado	1 asset por prompt; não gerar colagens compostas
Processamento determinístico de arquivos	Script validado	GPU e CPU locais	Checksum SHA-256, contagem e integridade	Custo zero de token; vedado uso de LLM para lógica fixa
Gate final de integração e merge	Responsável humano	Um integrador isolado por vez	Testes verdes, diff revisado e build de produção	Proibido uso de flags que desativem aprovação humana

5 DECOMPOSIÇÃO ESTRUTURADA DE CUSTOS

O custo operacional real de uma infraestrutura multiagente não é fixo. Ele deve ser decomposto formalmente em quatro camadas:

$$\text{Custo Operacional Total} = \text{Assinaturas Fixas} + \text{Impostos e Câmbio} + \text{API Variável} + \text{Computação Local}$$

1. Assinaturas Fixas Oficiais

- Claude Pro: US$ 20/mês nos Estados Unidos (ou US$ 17/mês no plano anual pago antecipadamente) (Claude Pricing);
- ChatGPT Plus: US$ 20/mês nos Estados Unidos (Codex Pricing);
- Google AI Pro: Valor varia conforme o país e a modalidade da conta Google (Antigravity Pricing; Google One Help).

2. Impostos e Câmbio

O total em reais depende do câmbio efetivo, do emissor do cartão e de tributos que apareçam na fatura. Como o estudo não dispõe das faturas nem da cotação aplicada, não converte os preços em dólar para reais.

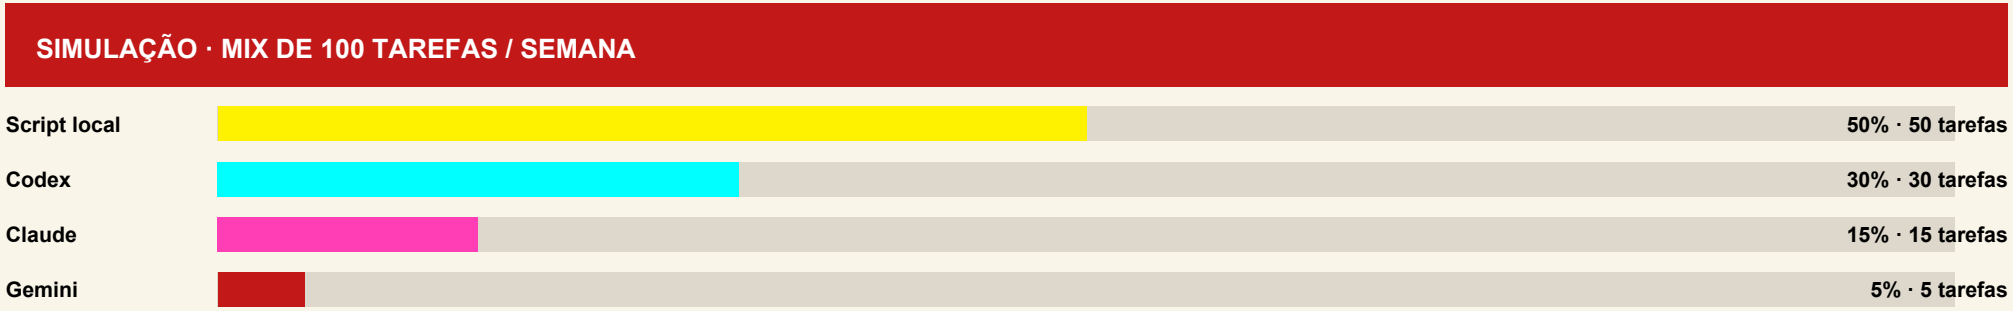
3. Consumo de API Variável

Ocorre quando chaves como `ANTHROPIC_API_KEY` ou `OPENAI_API_KEY` são ativadas em CLIs, quando ferramentas MCP utilizam endpoints pagos ou quando o controle de excedente do Antigravity é configurado como "Always".

4. Computação Local

Consumo de hardware da estação de trabalho (GPU dedicada e CPU em tarefas de build, renderização, conversão de assets e testes E2E locais), energia elétrica e banda. A telemetria local registrou 0,57 hora de GPU/CPU no pipeline analisado, sem potência média nem tarifa; não permite calcular custo de energia.

[SIMULAÇÃO] Cenário Modelado de Roteamento em Regime Piloto



Proposta de alocação, não dado medido. Tarefa ≠ token; valide qualidade, cota e retrabalho no piloto.

O gráfico representa uma hipótese de distribuição para 100 tarefas por semana. Os percentuais não representam tokens, saldo de cota ou economia em dinheiro.

Aviso Mandatório: A simulação a seguir é um modelo conceitual de engenharia para distribuição de carga. NÃO constitui previsão de fatura, garantia financeira ou medição de faturamento real.

Premissas da Simulação:

- Projeto executa volume representativo de 100 tarefas semanais de engenharia;
- Chaves de API e excedentes pagos desligados; sem assumir custo variável adicional.

Destino ilustrativo	Participação	Tarefas do cenário
Script local	50%	50
Codex	30%	30
Claude	15%	15
Gemini / Antigravity	5%	5

Leitura da simulação:

O mix 50/30/15/5 é um ponto de partida, não medição de desempenho, cota ou fatura. Só um piloto pode comparar consumo, qualidade e retrabalho; não há base para prometer economia ou eliminação de saturação.

6 O PILOTO QUE TRANSFORMA HIPÓTESE EM ENGENHARIA

Antes de adotar qualquer modelo como padrão ou alterar contratações, o protocolo estabelece a execução de um piloto controlado:

1. Corpus: 20 a 50 tarefas fechadas extraídas do próprio repositório, abrangendo testes unitários, refactors modulares, fluxos de terminal e páginas de UI;
2. Condições: Mesmo commit de origem, mesma especificação de requisitos, mesmo tempo limite e isolamento em worktrees;
3. Métrica Central: Taxa de tarefas aceitas por real e por hora, acompanhada pelo índice de retrabalho humano e defeitos em produção.

Resultado do Piloto	Decisão de Engenharia	Próxima Ação Prática
Worker rápido passa testes com mínimo retrabalho	Ampliar carga nessa classe de tarefa	Medir por mais uma semana mantendo auditoria cega
Modelo de fronteira reduz horas de revisão crítica	Reservar estritamente para contratos e gates	Manter concorrência em 1 worker e monitorar cota
Testes visuais identificam regressões não cobertas	Tornar etapa no browser obrigatória	Automatizar capturas de tela sem dispensar aprovação
Contexto cresce sem elevação no índice de aceite	Interromper sessão e isolar o escopo	Gerar artefato de handover, rodar `/clear` e reiniciar
Fornecedor atinge limite dinâmico de 5 horas	Suspender novos despachos ao fornecedor	Redirecionar trabalho para scripts locais determinísticos

7 SÍNTESE EXECUTIVA

Em engenharia de software agêntica, a pergunta crítica não é qual modelo "vence" benchmarks, mas qual arranjo entrega trabalho aceito com menos retrabalho e dentro de limites observáveis. A telemetria local mostra contexto e paralelismo altos no caso analisado; a documentação é compatível com esses fatores, mas não prova uma relação causal nem permite prever cotas. O uso proposto distribui decisão, execução, QA visual e operações determinísticas por necessidade. O piloto deve confirmar ou refutar essa hipótese antes de aumentar a carga de qualquer ferramenta.

8 BIBLIOGRAFIA ANOTADA

1. Anthropic. Claude Pricing. Preços-base, planos e limites gerais de modelos. Acesso em 31 out. 2026.
2. Anthropic. How do usage and length limits work?. Janela dinâmica de 5 horas e limite semanal. Acesso em 31 out. 2026.
3. Anthropic. Models, usage, and limits in Claude Code. Boas práticas de contexto, `/clear`, `/compact`, `/context` e alocação de modelos. Acesso em 31 out. 2026.
4. Anthropic. Use Claude Code with your Pro or Max plan. Regras de autenticação por assinatura e separação de faturamento de API. Acesso em 31 out. 2026.
5. Anthropic. Claude Code CLI usage. Interface oficial de automação por terminal e flags. Acesso em 31 out. 2026.
6. OpenAI. Introducing the Codex app. Centro de comando para múltiplos agentes paralelos e worktrees. Acesso em 31 out. 2026.
7. OpenAI. Using Codex with your ChatGPT plan. Escopo da assinatura ChatGPT, interfaces e distinção de API. Acesso em 31 out. 2026.
8. OpenAI. Codex Pricing. Faixas estimadas de tarefas por modelo e limites de consumo. Acesso em 31 out. 2026.
9. OpenAI. Using your ChatGPT plan in other apps and sites. Políticas de uso de conta fora dos clientes proprietários. Acesso em 31 out. 2026.
10. Google. Antigravity 2.0, Pricing e Choose a model. Recursos autônomos, modelos suportados e regras de quota. Acesso em 31 out. 2026.
11. Google. Antigravity CLI e Google One Help: Antigravity. Login por chaveiro de sistema, pooling de créditos e controle de excedente. Acesso em 31 out. 2026.
12. Google. Aviso sobre ferramentas de terceiros. Diretrizes oficiais contra o uso de proxies não homologados. Acesso em 31 out. 2026.
13. SWE-bench. Página oficial. Metodologia de avaliação de software, dataset Verified e ambiente padronizado. Acesso em 31 out. 2026.
14. Artificial Analysis. Metodologia de inteligência, Intelligence Index v5.0 e leaderboard. Snapshots de FrontierCode 2.0, Terminal-Bench e custo por tarefa. Acesso em 31 out. 2026.

15. LLM Stats. Research e leaderboard. Ratings relativos e modelos estatísticos de incerteza. Acesso em 31 out. 2026.

16. OpenRouter. Rankings. Tráfego e demanda pública de marketplace. Acesso em 31 out. 2026.

17. Artificial Analysis. Metodologia de imagem, geração e edição. Leaderboard de preferência humana cega em geração e edição de imagens. Acesso em 31 out. 2026.

18. Reddit e repositórios de experimentos. Opus para planejar e Codex para executar; seis projetos Codex vs Claude; repositório do experimento. Relatos de engenharia independentes. Acesso em 31 out. 2026.

19. Relatos de comunidade. Quotas Codex, comparativo dos três aplicativos e cache no Claude. Evidências qualitativas de modos de falha. Acesso em 31 out. 2026.

20. Nimbalyst e Paradev. Nimbalyst; Paradev; mudança de nome; instalação Paradev. Licenciamento, arquitetura e limites de compatibilidade. Acesso em 31 out. 2026.

21. Evidência local auditada. Snapshot de telemetria de 31 out. 2026 (`telemetria-ia-ultima.json`, `telemetria-ia-historico.csv`); logs do pipeline R06 e transcrições de sessão. Dados restritos ao estudo de caso local.